

**T.C.  
PAMUKKALE ÜNİVERSİTESİ  
İKTİSADİ VE İDARİ BİLİMLER FAKÜLTESİ  
YÖNETİM BİLİŞİM SİSTEMLERİ BÖLÜMÜ**



**HAVA KİRLİLİĞİNİN COVID-19 ENFEKTE SAYILARININ ETKİSİ ÜZERİNE  
OLAN MODELLERİN MAKİNE ÖĞRENMESİ TEKNİKLERİ ARASINDAKİ  
PERFORMANS KARŞILAŞTIRMASI**

**LİSANS TEZİ**

**FURKAN YUSUF BOZBIYIK**

**DENİZLİ, HAZİRAN - 2021**

## İÇİNDEKİLER

İÇİNDEKİLER .....	i
KISALTMALAR .....	iv
ÇİZELGE LİSTESİ .....	v
ŞEKİL LİSTESİ .....	v
ÖZET .....	vi
1. GİRİŞ .....	1
1. 1 Tezin Bölümleri.....	1
2. İLGİLİ ÇALIŞMALAR .....	2
3. AMAÇ VE PROBLEM.....	3
3. 1 Amaç .....	3
3. 2 Problem .....	3
4. MAKİNE ÖĞRENİMİ .....	4
4. 1 Öznitelik Kavramı.....	4
4. 2 Veri Türleri.....	4
4.2.1 Sayısal (Nicel) Veriler.....	4
4.2.1.1 Ayırık (Discreate) Veriler .....	4
4.2.1.2 Sürekli (Continious) Veriler .....	4
4.2.2 Kategorik (Nitel) Veriler .....	5
4.2.2.1 Sıralı (Ordinal) Veriler .....	5
4.2.2.2 Nominal Veriler .....	5
4.3 Öğrenme Türleri.....	5
4.3.1 Denetimli Öğrenme.....	6
4.3.1.1 Regresyon .....	6
4.3.1.2 Sınıflandırma.....	7
4.3.2 Denetimsiz Öğrenme .....	7
4.3.2.1 Kümeleme .....	7
4.3.2.2 Boyut Azaltma .....	8

4.3.3 Takviyeli Öğrenme.....	8
4.4 Kullanılan Teknikler .....	8
4.4.1 Doğrusal Regresyon (Linear Regression).....	8
4.4.2 Destek Vektör Regresyon (Support Vector Regression) .....	9
4.4.3 Yapay Sinir Ağları (Artificial Neural Network).....	10
4.4.4 Long Short-Term Memory (Uzun Kısa Süreli Bellek) .....	11
<b>5. MODEL GELİŞTİRME SÜRECİ.....</b>	<b>12</b>
5.1 Veri Ön İşleme (Data Preprocessing).....	13
5.1.1 Eksik Veri Analizi .....	13
5.1.2 Veri Dönüştürme .....	13
5.1.2.1 Etiket Kodlama (Label Encoding) .....	13
5.1.2.2 One-Hot Kodlama.....	14
5.2 Eğitim Ve Test Setinin Oluşturulması.....	14
5.3 Veri Ölçeklendirme .....	14
5.3.1 Min – Max Normalizasyonu .....	15
<b>6. PERFORMANS DEĞERLENDİRME ÖLÇÜTLERİ .....</b>	<b>15</b>
6.1 Ortalama Mutlak Hata (Mean Absolute Error) .....	15
6.2 Ortalama Kare Hata (Mean Squared Error) .....	15
6.3 Ortalama Kare Hata Karekökü (Root Mean Squared Error) .....	16
6.4 Medyan Mutlak Hata (Median Absolute Error).....	16
6.5 Belirlenme Katsayısı (Determination Coefficient) .....	16
<b>7. KULLANILAN VERİLER .....</b>	<b>17</b>
7.1 COVID-19.....	17
7.1.1 Verileri Elde Etme.....	17
7.1.2 Seçilen Tarih Aralığı .....	17
7.2 Hava Kalitesi.....	17
7.2.1 Verileri Elde Etme.....	17
7.2.2 Seçilen Tarih Aralığı Ve İller.....	17
7.2.3 Kirleticilerin Çeşitleri .....	18
7.2.4 Verilerin Düzenlenmesi.....	18
7.2.5 Hava Kalite İndeksi.....	18

<b>8. TESTLER VE BULGULAR</b>	18
8.1 Doğrusal Regresyon	18
8.1.1 Kış Verileriyle Modelin Testi	19
8.1.1.1 Modelin Performans Ölçümü	20
8.1.2 Yaz Verileriyle Modelin Testi	20
8.1.2.1 Modelin Performans Ölçümü	22
8.2 Destek Vektör Regresyon	22
8.2.1 Kış Verileriyle Modelin Testi	22
8.2.1.1 Modelin Performans Ölçümü	24
8.2.2 Yaz Verileriyle Modelin Testi	24
8.2.2.1 Modelin Performans Ölçümü	26
8.3 Yapay Sinir Ağları	26
8.3.1 Kış Verileriyle Modelin Testi	26
8.3.2 Yaz Verileriyle Modelin Testi	27
8.3.3 Modelin Performansı	28
8.3.4 Değerlendirme	31
8.4 LSTM	31
8.4.1 Kış Verileriyle Modelin Testi	31
8.4.2 Yaz Verileriyle Modelin Testi	32
8.4.3 Modelin Performansı	33
8.4.4 Değerlendirme	34
<b>9. SONUÇ VE KARŞILAŞTIRMA</b>	35
<b>EKLER</b>	36
EK-A YSA Modelinin Ağırlıkları	36
EK-B LSTM Modelinin Ağırlıkları	40
<b>KAYNAKÇA</b>	50

## KISALTMALAR

<b>COVID-19</b>	: Coronavirus Disease 2019
<b>PM10</b>	: Particular Matter 10
<b>PM2.5</b>	: Particular Matter 2.5
<b>GSYİH</b>	: Gayri Safi Yurt İçi Hasıla
<b>DVM</b>	: Destek Vektör Makinesi
<b>YSA</b>	: Yapay Sinir Ağları
<b>ÇKA</b>	: Çok Katmanlı Algılayıcılar
<b>CO</b>	: Karbon Monoksit
<b>NO2</b>	: Nitrojen Oksit
<b>O3</b>	: Ozon
<b>SO2</b>	: Sülfür Dioksit
<b>LSTM</b>	: Long Short-Term Memory
<b>PCA</b>	: Principal Component Analysis
<b>VC</b>	: Vapnik-Chervonenkis
<b>DVR</b>	: Destek Vektör Regresyonu
<b>TSA</b>	: Tekrarlayan Sinir Ağları
<b>MAE</b>	: Mean Absolute Error
<b>MSE</b>	: Mean Squared Error
<b>RMSE</b>	: Root Means Squared Error
<b>MedAE</b>	: Median Absolute Error
<b>NOx</b>	: Nitrogen Oxide
<b>AB</b>	: Avrupa Birliği
<b>DR</b>	: Doğrusal Regresyon
<b>DVR</b>	: Destek Vektör Regresyonu
<b>ReLU</b>	: Rectified Linear Unit
<b>tanh</b>	: Hyperbolic Tangent

## ÇİZELGE LİSTESİ

Sayfa

Çizelge 10.1 Regresyonlar için modellerin ortalama performans skorları.....	35
Çizelge 10.2 YSA ve LSTM modellerinin ortalama performans skorları.....	35

## ŞEKİL LİSTESİ

Sayfa

Şekil 1: Makine Öğrenimi Çalışma Alanları.....	6
Şekil 2: YSA Mimarisi Örneği.....	10
Şekil 3: LSTM Mimarisi Örneği.....	12
Şekil 4: Model Geliştirme Süreçleri.....	12
Şekil 5: Etiket kodlamaya bir örnek.....	14
Şekil 6: One-Hot kodlamaya bir örnek.....	14
Şekil 7: DR kış eğitim verileri modelinin öğrenme eğrisi.....	19
Şekil 8: DR kış test verileri modelinin öğrenme eğrisi.....	19
Şekil 9: DR yaz eğitim verileri modelinin öğrenme eğrisi.....	21
Şekil 10: DR yaz test verileri modelinin öğrenme eğrisi.....	21
Şekil 11: DVR kış eğitim verileri modelinin öğrenme eğrisi.....	23
Şekil 12: DVR kış test verileri modelinin öğrenme eğrisi.....	23
Şekil 13: DVR yaz eğitim verileri modelinin öğrenme eğrisi.....	25
Şekil 14: DVR yaz test verileri modelinin öğrenme eğrisi.....	25
Şekil 15: YSA kış verisi modelinin öğrenme eğrisi.....	27
Şekil 16: YSA yaz verisi modelinin öğrenme eğrisi.....	28
Şekil 17: Uyumsuz (underfit) eğrisi.....	29
Şekil 18: Aşırı uyum (overfitting) eğrisi.....	30
Şekil 19: İyi uyum eğrisi (good fit) .....	30
Şekil 20: LSTM kış verisi modelinin öğrenme eğrisi.....	31
Şekil 21: LSTM yaz verisi modelinin öğrenme eğrisi.....	32
Şekil 22: Temsili olmayan doğrulama veri seti öğrenme eğrisi.....	34

## ÖZET

COVID-19'un etkisini sürdürdüğü 2020 ve 2021 yıllarında milyonlarca insan COVID-19'dan etkilenmiş ve hayatını yitirmiştir. Bunların önüne geçmek için çoğu ülke kapanma, maske takmak gibi önlemler alınmıştır. Bir diğer önlem ise tıp alanındaki bilim insanlarının bulduğu aşılar olmuştur. Bu önlemleri etkili şekilde kullanan ülkelerde COVID-19'un etkisini giderek azaltmaktadır. Alınabilecek önlemler arasında COVID-19'dan enfekte olmayı önceden tahmin etmeye çalışmaktır. Tahmin yöntemleri içinde makine öğrenimi yöntemleri öne çıkmaktadır. Bu çalışmada makine öğrenimi teknikleri kullanılmıştır. Makine öğrenimi bağımlı ve bağımsız değişkenler almaktadır. Bu çalışmada bağımsız değişken olarak hava kirliliği (PM10) verileri, bağımlı değişken olaraksa COVID-19 enfekte sayıları kullanılmıştır. Makine öğrenmesini uygulamak için çeşitli teknikleri vardır. Bu çalışmada doğrusal regresyon, destek vektör regresyon, yapay sinir ağları, long short-term teknikleri kullanılmıştır. Bu tekniklerin performansları bu çalışmada karşılaştırılmıştır. Çıkan sonuca göre yapay sinir ağları, LSTM ve destek vektör regresyonu ön plana çıkmaktadır

# 1. GİRİŞ

Salgın hastalıklar, insanlığı ve onun sağlığını her zaman kötü etkilemiştir. Bu durum COVID-19 salgınında da farklı değildir. Salgın başladığından beri dünyada milyonlarca insan enfekte olmuş ve hayatını kaybetmiştir. Bu durum enfekte veya ölüm sayılarına nelerin etki ettiği ve önceden tahmin edilip edilemeyeceği konusu merak konusu olmuştur. Tahmin denildiği zaman bilgisayar bilimlerinin yapay zeka alanı ve onunda alt dalı olan makine öğrenmesi akla gelir. Makine öğrenmesine tahminler çeşitli tekniklerle yapılır ve bu teknikler ile etki de ölçülebilir. Bu tekniklerin performansı veri setinden veri setine değişiklik gösterir, bu nedenle veri setine uygun teknik seçmek önemlidir. Bu çalışmada hava kirliliğinin COVID-19 enfekte sayıları üzerindeki etkisi ölçmek ve seçilen tekniklerin performansları üzerinden karşılaştırma yapılmak istenmiştir. Bu nedenle bu veri seti COVID-19 enfekte verileri, diğer bir veri seti ise hava kirliliği verileridir. Hava kirliliği parametresi olarak PM10 (Particular Matter 10) seçilmiştir. Bu çalışmada model Python dilinde geliştirilmiştir.

## 1.1 Tezin Bölümleri

Birinci bölümde tezin giriş bölümüdür. Bu bölümde tez hakkında giriş niteliğinde bilgiler verilmiş ve tezin tanıtımı yapılmıştır.

İkinci bölümde tezin literatür taraması yapılmıştır yani konusuna uygun makaleler bulunup derlenmiş ve makalelerden özet niteliğinde bilgiler verilmiştir.

Üçüncü bölümde ise amaç tanımlanmış ve çözülmesi beklenen problemler belirlenmiştir.

Dördüncü bölümde Makine öğrenimi hakkında bilgiler verilmiştir. Makine öğreniminde kullanılan öznitelik kavramını ve veri türlerini, öğrenme türlerini ve bu türlerin kapsadığı makine öğrenmesi tekniklerini ve son olarak modelde kullanılan makine öğrenimi tekniklerinin tarihi ve tanımı verilmiştir.

Beşinci bölümde ise model geliştirme sürecine odaklanılmıştır. Bu nedenle veri ön işleme süreçleri, veri setlerinin eğitim ve test olarak ayrılması süreçlerini ve son olarak veri ölçeklendirme süreçleri anlatılmıştır.



Altıncı Bölümde modelde kullanılan performans değerlendirme ölçütlerine değinilmiştir. Bu bölümde ele alınan performans değerlendirme ölçütleri şunlardır: ortalama mutlak hata, ortalama kare hata, ortalama kare hata karekökü, medyan mutlak hata, belirleme katsayısı.

Yedinci bölümde hava kalitesi ile ilgili bilgiler verilmiştir. Bu bölümde hava kirliliği verilerinin nasıl elde edildiği, seçilen zaman aralığını, kirlletici çeşitlerine, verilerin nasıl düzenlendiğine, hava kalite indeksine ve hangi kirleticinin seçildiğine değinilmiştir.

Sekizinci bölümde veri setleriyle test edilen modelden elde edilen bulgular ortaya konmuştur. Bulgular yaz ve kış olarak ayrılmış, model hakkında bilgiler verilmiş ve performans değerlendirme ölçütleriyle değerlendirilmiştir.

Dokuzuncu bölümde elde edilen performans değerleri karşılaştırılmış ve öne çıkan teknikler listelenmiştir. Son olarak öneriler yazılmıştır.

## **2. İLGİLİ ÇALIŞMALAR**

Literatürde COVID-19 ve makine öğrenimimi konularında her iki konuyla yapılan çalışmalar azdır. Literatürde olan çalışmalar incelendiğinde hava kirliliği kirliliği (PM10) ile COVID-19 verilerinin etkisinin test edildiği bazı çalışmalar şunlardır: Fransa'nın üç şehrinde (Paris, Lyon, Marsilya) yapılan çalışmada, COVID-19 salgını ile hava kirliliği (PM10, PM2.5) arasındaki ilişki ve salgını yaymadaki rolü için yapay sinir ağı modeli kurulmuş ve buldukları hava kirliliği eşik seviyesi Avrupa Parlamentosu tarafından koyulan eşik değerden daha yüksek çıkmıştır [1]. Bir diğer örnekte ise COVID-19'un yayılımını belirlemek için makine öğrenmesi modeli geliştirmek amacıyla Kaliforniya Devlet Üniversitesin'de yapılan çalışmada, modelin bağımsız değişkenine hava kirliliği, sıcaklık, GSYİH ve demografik değişkenler eklenerek doğrusal regresyon, destek vektör makinesi (DVM), radyal çekirdek (DVM), polinom çekirdek (DVM) ve karar ağacı gibi makine öğrenimi teknikleri kullanılarak testler yapılmış ve ortaya çıkan bulgulardan biri de hava kirliliğinin COVID-19 yayılım hızını arttırabileceği saptanmış [2]. Brezilya'nın Sau Paulo şehrinde yapılan bir başka çalışmada kapanma dönemlerinde hava kirliliği (PM2.5 ve PM10) günlük COVID-19 vaka sayıları, kısmi kapanma seviyesi ve meteorolojik

değişkenler olmak üzere çeşitli veriler yapay sinir ağları (YSA) modellerini (Çok Katmanlı Algılayıcı (ÇKA), Radyal temel, Extreme Learning Machines, Echo State Networks) beslediler ve karşılaştırdılar. ÇKA'nın diğer YSA modellerinden daha iyi performans verdiği görülmüş ve esnek kapanma önlemleri ile hava kirliliğinin kontrol edilebileceği saptanmış [3]. Diğer bir çalışma da ise İtalya'da makine öğrenimi yardımıyla hava kirliliği (PM2.5) ve COVID-19 ölüm ve pozitiflik oranları arasındaki ilişkiyi incelenmiş ve hava kirliliğinin %5-10'luk artışında dahi salgının artabileceği saptanmış [4]. Peru Lima'da yapılan bir diğer çalışmada ise kapanma dönemlerinde hava kirliliği (CO (karbon monoksit), NO2 (nitrojen oksit), O3 (ozon), SO2 (sülfür dioksit), PM10, PM2.5) verilerinin azalıp azalmadığının ve COVID-19 enfeksiyon verileriyle ilişkisi incelenmiştir ve Gauss Süreci Regresyonu ile bir sınıflandırma modeli önerilmiştir. COVID-19 enfeksiyonun yüksek düzeyde görüldüğü yerlerde NO2 ve PM10 ile korelasyon tespit edilmiş [5].

### **3. AMAÇ VE PROBLEM**

#### **3.1 Amaç**

Bu tezin amacı, hava kirliliği (PM10) verilerinin COVID-19 enfekte sayılarının etkisi üzerine doğrusal regresyon, destek vektör regresyon, yapay sinir ağları ve uzun-kısa süreli bellek (LSTM) tekniklerinden oluşturulan modellerin, model geliştirme sürecinden geçerek, arasındaki etkisini ölçerek performans ölçütleriyle karşılaştırma yapmaktır.

#### **3.2 Problem**

Bu tezde aşağıda belirtilen problemlerin çözülmesi beklenmektedir:

1. Tezde kullanılan makine öğrenmesi tekniklerinin hangisinin daha iyi performans gösterdiği.
2. Covid-19 enfekte verileriyle makine öğrenmesi alanında çalışma yapacak kişilerin hangi tekniği seçecekleri.
3. Modelin ağırlıkları verildiği için, araştırmacılar hangi modeli kendi çalışmalarında kullanabilecekleri.

## 4. MAKİNE ÖĞRENİMİ

Makine Öğrenimi, otomatik olarak öğrenebilen ve bu öğrenmenin sonucunda tahmin yapabilen algoritmalar ve yapay zekanın alt dalıdır [6]. Makine öğrenimi istatistik ve bilgisayar biliminin birleşme noktasında yer alır. Makine öğrenimi iki soruya odaklanmaktadır: Nasıl deneyim yoluyla ve kendi kendine gelişen bilgisayarlar inşa edilebilir? Öğrenme sistemini yöneten istatistiksel, bilgi ve hesaplama teorik yasaları nelerdir? [7]

### 4.1 Öznitelik Kavramı

Bir veri seti satır ve sütunlardan oluşan iki boyutlu matrislerden oluşur. Satırlar örnek (sample), sütunlar öznitelik (feature) olarak adlandırılır. Veri setindeki son sütun ise sınıf (class) özel olarak isimlendirilir. Makine öğrenmesi terminolojisinde öznitelikler girdi, sınıf ise çıktı olarak ifade edilir [8].

### 4.2 Veri Türleri

Veri türleri ikiye ayrılır: sayısal (nicel) veriler ve kategorik (nitel) veriler [8].

#### 4.2.1 Sayısal (Nicel) Verileri

Sayısal veriler ikiye ayrılır: ayrık (discrete) veriler ve sürekli (continuous) veriler.

##### 4.2.1.1 Ayrık (Discrete) Veriler

Ayrık veriler birbirinden ayrılabilen, boşluklar, kesintiler olabilen verilerdir. Örneğin: 3 armut, 5 uçak vb. gibi.

##### 4.2.1.2 Sürekli (Continuous) Verileri

Sürekli veriler, ölçümler veya gözlemler ile üretilen boşluklar, kesintiler veya sıçramaları olmayan, bir dizi değeri içeren sürekli ölçeğe denk gelen verilerdir. Örneğin: 10 mm olarak ölçülen bir nokta daha hassas ölçü aletiyle 10.23 gibi bir değer olabilir ve bu sonsuza kadar sürebilir.

#### **4.2.2 Kategorik (Nitel) Veriler**

Sıralı (Ordinal) ve nominal olmak üzere 2'ye ayrılır.

##### **4.2.2.1 Sıralı (Ordinal) Verileri**

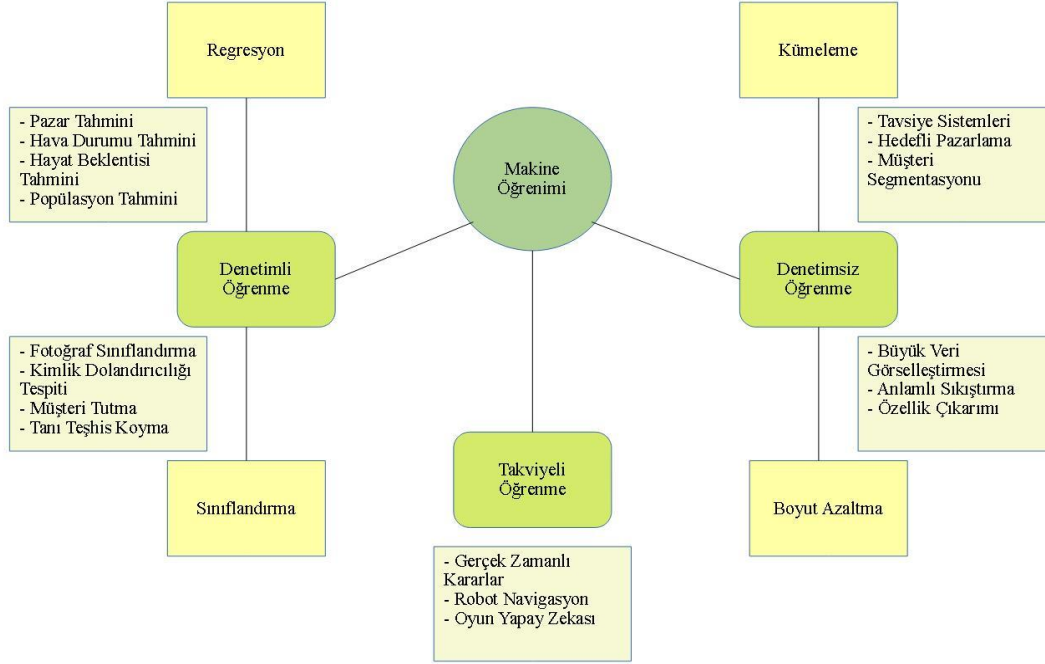
Sıralanabilen verilerdir. Örneğin: İlkokulda karnelerdeki 5'lik puan notu, başarısız, geçer, orta, iyi, pekiyi olarak sıralanır.

##### **4.2.2.2 Nominal Veriler**

Sıralaması mümkün olamayan verileri içerirler. Örneğin: cinsiyet, medeni durum vb. gibi.

#### **4.3 Öğrenme Türleri**

Makine öğreniminde pratikteki problemlerin çözümü için 3 öğrenme türü vardır. Bunlar: denetimli öğrenme (supervised learning), denetimsiz öğrenme (unsupervised learning) ve takviyeli öğrenmedir (reinforcement learning). Bu öğrenme türleri aşağıdaki şekilde detaylarıyla gösterilmiştir.



**Şekil 1.** Makine öğrenimi çalışma alanları [8]

#### 4.3.1. Denetimli Öğrenme

Girdi ile alınan çeşitli örneklerin denetimli makine öğrenmesi algoritmalarıyla öğrenip test edildikten sonra çıktı ile girdi değerinin ne kadar uyduğu bulunmasıdır ve eğer fark optimal sınırların dışında ise bazı fonksiyonlar ile optimize edilmesidir. Öğretmenli öğrenme olarak da adlandırılır [6]. Regresyon ve sınıflandırma olarak ikiye ayrılmıştır.

##### 4.3.1.1 Regresyon

Regresyon yönteminde girdi (bağımsız değişken) ve çıktıdan (bağımlı değişken) oluşur. Eğer çıktı değeri sürekli veriden oluşuyorsa o veri seti için regresyon yöntemi kullanılır. Burada amaç girdi değerinin çıktı değeri üzerindeki etkisini ölçmektir [8]. Bazı regresyon tekniklerine örnek:

- Doğrusal Regresyon (Linear Regression)
- Polinom Regresyon (Polynomial Regression)

- Destek Vektör Regresyonu (Support Vector Regression)
- Karar Ağacı Regresyon (Decision Tree Regression)

#### **4.3.1.2 Sınıflandırma**

Sınıfı bilinmeyen ve ayrık verilerden oluşan verileri sınıflandırma eğrisiyle birbirinden ayrılmasına sınıflandırma denir [8]. Bazı sınıflandırma teknikleri aşağıda verilmiştir:

- Destek Vektör Makineleri (Support Vector Machine)
- Yapay Sinir Ağları (Artificial Neural Network)
- k-En Yakın Komşu Algoritması (k-Nearest Neighbour Algorithm)
- Karar Ağaçları (Decision Tree)

#### **4.3.2 Denetimsiz Öğrenme**

Çıktı değeri almadan yapılan öğrenmedir. Girdi verisine göre model analiz yapar ve çıktıyı tahmin etmeyi amaçlar. Öğretimsiz öğrenme olarak da adlandırılır [6]. Kümeleme ve boyut azaltma olarak ikiye ayrılır.

##### **4.3.2.1 Kümeleme**

Veri setindeki örnekler arasındaki benzerlik ölçümlerinin (similarity measurement) ölçümüne dayanır. Benzerlik ölçümü geometrik şekillere dayanır ve bu şekillerle hangi kümeye ait olduğu bulunur [8]. Bazı kümeleme teknikleri aşağıda verilmiştir:

- k-Ortalamalar Algoritması (k-Means Algorithm)
- Hiyerarşik Küme Analizi (Hierarchical Cluster Analysis)

#### 4.3.2.2 Boyut Azaltma

Artan veri miktarıyla beraber birbiriyle benzer olan veriler de artmıştır, bu modelin hatalı sonuç üretmesine neden olabilmektedir. Ayrıca vektörler ve matrisler gibi yüksek işlem gücü gerektiren hesaplamalar modelin performansını düşürmüştür. Bu nedenle veri setinin özü korunurken boyut azaltma işlemi yapılması gereksinimi doğmuştur. Örneğin: 3 boyutlu uzayda temsil edilen verilerin, 2 boyutlu uzaya indirgenmesi gibi [8]. Aşağıda bazı boyut azaltma teknikleri verilmiştir:

- Temel Bileşene Analizi (Principal Component Analysis, PCA)
- Kernel PCA

#### 4.3.3 Takviyeli Öğrenme

Eğitim psikolojisinde yer alan “Takviyeli Öğrenme” yaklaşımından esinlenen takviyeli öğrenme tekniği, ödül ceza prensibine dayanır. Girdi verisi ileri yayılma algoritmasından geçmekte ve çıktı üretilmekte, bu çıktının doğruluğu kontrol edilip modele geri bildirimde bulunmaktadır. Eğer çıktı verisi istenilen gibi değilse model ağırlıklarında iyileştirme yapılmaktadır [6]. Bazı takviyeli öğrenme teknikleri aşağıda verilmiştir:

- Q-Learning
- State-Action-Reward-State-Action
- Deep Q Network

#### 4.4 Kullanılan Teknikler

Bu tezin amacı doğrultusunda kullanılan teknikler aşağıda verilmiştir. Bu teknikler genel itibariyle tanım ve tarihçe olmak üzere iki ana başlıkta incelenmiştir.

##### 4.4.1. Doğrusal Regresyon (Linear Regression)

## Tanım

Regresyon sayısal verilerden oluşur. Regresyon analizi, girdi sabit olduğunda hedefin beklenen değerinin tahminine denir. Regresyon analizinin doğrusal ilişki olduğu varsayıldığında buna doğrusal regresyon denir [9]. Doğrusal regresyon fonksiyonu aşağıda verilmiştir:

$$Y = a + bX$$

Buradaki Y bağımlı yani hedef değişkenidir, X bağımsız yani girdi değişkenidir. a ve b değişkenleri ise fonksiyonu etkileyen ağırlık parametrelerdir. a parametresi aynı zamanda bias olarak adlandırılır. Doğrusal regresyonun anlamlılığı belirleme katsayısı ( $R^2$ ) ile ölçülür. Bu katsayı 1 değerine ne kadar yakın olursa model o kadar anlamlıdır. Regresyon modelinin anlamlı olması nedensellik ifade etmez [10].

### 4.4.2. Destek Vektör Regresyonu (Support Vector Regression)

## Tanım

Destek vektör makinesi, geliştirilen genelleştirilmiş betimleme metodu ve istatistiksel öğrenme teorisine dayanan sınıflandırma tekniğidir [11]. Temeli Vapnik-Chervonenkis (VC) teorisine dayanır. Bu teori verinin dağılımdan bağımsız şekilde en uygun modeli bulmayı amaçlar. VC teorisi genelleştirilmiş bir model amaçlar, yani önceden model tarafından görülmemiş model yapmayı amaçlar [12]. Destek vektör regresyonu (DVR), sınıflandırıcı destek vektör makinesinin regresyon halidir. DVR’de amaç beklenen tahmin hatasını minimize edecek bir fonksiyon bulmaktır [11].

## Tarihçe


Destek vektör makinesinin (DVM) temeli Vladimir Vapnik ve Alexey Chervonenkis tarafından 1964 yılında geliştirilmiştir. Vapnik ve Chervonenkis’in 1974 yılında istatistiksel öğrenme teorisi üzerine çalışmaları ile 1979 yılında DVM’yi geliştirilmeye başlanıp, 1995’te Cortes ve Vapnik tarafından yayınlanan “Support-Vector Networks” adlı makaleyle son halini almıştır [12]. SVR, Smola ve Schölkopf tarafından yayınlanan “A tutorial on support vector regression” adlı makalede ileri sürülmüştür.



#### 4.4.3. Yapay Sinir Ağları (Artificial Neural Network)

##### Tanım

Yapay sinir ağları (YSA), biyolojiden insan beyninin nöron ve sinaps yapılarından hareketle bilgisayar bilimlerine, nöron bağlantıları ve bunların ağırlıkları olarak geçmiş bir teknolojidir [13]. YSA algoritmalarının temelinde öğrenme modeli yer alır. Öğrenme modeli, gerçek çıktı ile ağın ürettiği çıktı değeri arasındaki farkın toplamının (hata fonksiyonu) minimize edilerek ağırlıkların güncellenmesi teknikleridir [8]. Bu teoride regresyonla aynıdır. Tek farkı bir sinir ağı modelinde uygulanmasıdır [14].



Şekil 2. YSA mimarisi örneği

##### Tarihçe

İlk defa 1943 yılında araştırmacılar Warren McCulloch ve Walter Pitts tarafından basit bir model oluşturulmuştur [15]. Daha sonra 1949 yılında Hebb tarafından daha sonra Hebb’ci öğrenme kuralı olarak da bilinen bir tez ortaya atılmıştır. Bu teze göre bir sinapsın her iki tarafındaki nöronlar aynı anda etkinse ikisi arasındaki ağırlık artar yani ikisi arasındaki bağ güçlenir, bu da öğrenme için bir adımdır [14]. 1962 Frank Rosenblatt adlı psikolog tarafından yazılan “Principles of Neurodynamics: Perceptrons and the Theory of Brain Mechanisms (Nörodinamiğin Prensipleri: Algılayıcılar Ve Beyin Mekanizmasının

Teorisi)’’ adlı kitapta algılayıcı (perceptron) ağı modeli oluşturulmuştur. Bu modelde nöronlar bir etkilenim [activation] değerine sahip yapay nöronlardan aralarındaki sinaps bağlantıları olarak oluşur [8].

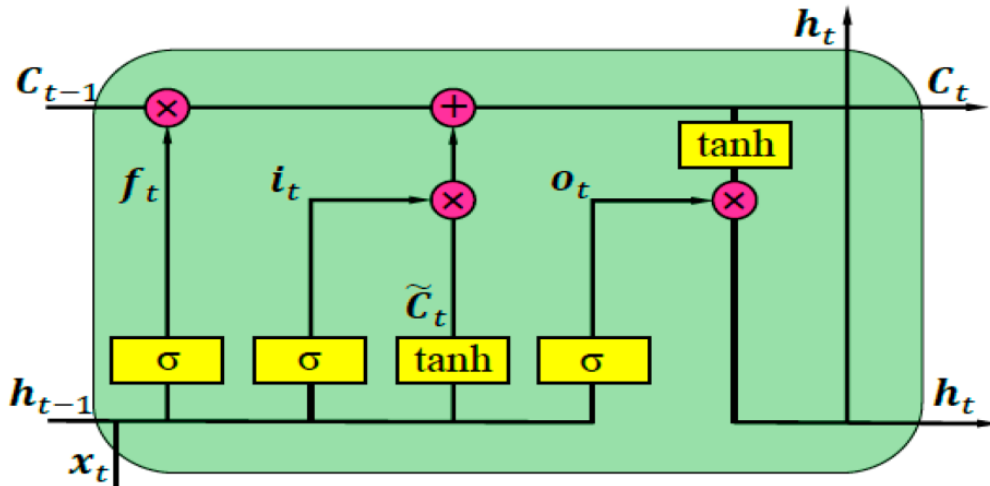
#### 4.4.4. Long Short-Term Memory (Uzun Kısa Süreli Bellek)

##### Tanım

Tekrarlayan sinir ağları (TSA) girdi verisinden bir önceki çıktı değerini dikkate alarak tekrarlı incelenmesi yöntemine denir ve yapay sinir ağlarının alt dalıdır [16]. Long Short-Term Memory (LSTM), geri beslemeli tekrarlayan ağların kaybolan ve patlayan gradyan problemlerini çözmek amacıyla öne sürülen tekrarlayan sinir ağı mimarili bir derin öğrenme tekniğidir [17]. LSTM genel olarak unut, girdi ve çıktı olmak üzere 3 katmandan oluşur. Aşağıda bir sinir ağının işlem fonksiyonları verilmiştir:

1.  $i_t = \sigma (W_{xi} x_t + W_{hi} h_{t-1} + W_{ci} c_{t-1} + b_i)$
2.  $f_t = \sigma (W_{xf} x_t + W_{hf} h_{t-1} + W_{cf} c_{t-1} + b_f)$
3.  $c_t = f_t \odot c_{t-1} + i_t \odot \tanh (W_{xc} x_t + W_{hc} h_{t-1} + b_c)$
4.  $o_t = \sigma (W_{xo} x_t + W_{ho} h_{t-1} + W_{co} c_t + b_o)$
5.  $h_t = o_t \odot h_{(ct)}$

$i$ ,  $o$ ,  $f$ ,  $c$ ,  $W$ ,  $\odot$ ,  $\sigma$  değişkenleri sırasıyla girdi kapısı, çıktı kapısı, unut kapısı, hücre aktivasyon vektörü, ağırlık matrisini, iki metriğin skeler çarpımını ve sigmoid fonksiyonunu ifade eder [18].



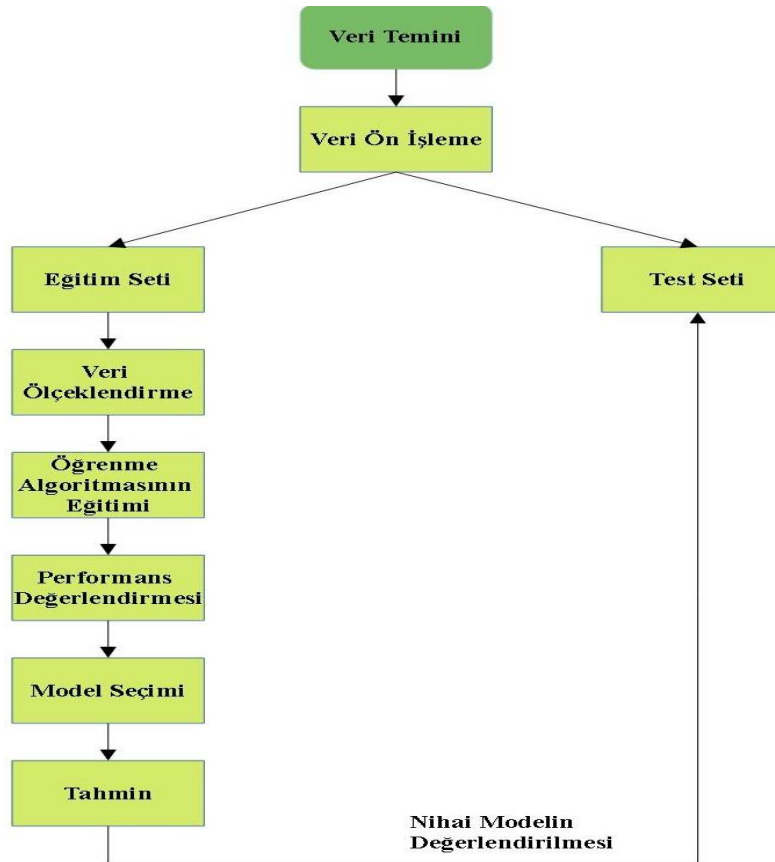
**Şekil 3.** LSTM mimarisi örneği [19]

## Tarihçe

LSTM ilk defa 1997’de Sepp Hochreiter ve Jurgen Schmidhuber tarafından yazılan “Long Short-Term Memory” adlı makalede ortaya konmuştur. 1999 yılındaysa LSTM’ye unut kapısı Felix Gers ve Jurgen Schmidhuber tarafından yazılan “Learning to Forget: Continual Prediction with LSTM” adlı makalede eklenmiştir.

## 5. MODEL GELİŞTİRME SÜRECİ

Bu bölümde makine öğrenmesi modelinin geliştirilirken hangi aşamalardan geçtiği ele alınacaktır. Şekil 4’te model geliştirme süreçleri verilmiştir.



## **Şekil 4. Model geliştirme süreçleri**

### **5.1 Veri Ön İşleme (Data Preprocessing)**

Veri ön işleme süreci, verinin modele hazır duruma getirilme sürecidir. Modelin performansı açısından önemlidir.

#### **5.1.1 Eksik Veri Analizi**

Modeli oluşturulacak olan veri setinin analizi yapılır. Eğer bazı veriler eksik veya yanlış ise o veri seti üç şekilde düzeltilebilir: [20]

- 1 Eksik verinin bulunduğu satır veri setinden silinebilir.
- 2 Eksik veri sayısal bir veri ise, o özniteliğe ait verilerin ortalaması alınabilir, eğer eksik veri kategorik veri ise özniteliğin frekans sıklığı en yüksek olan veri eksik veri yerine yazılabilir.
- 3 Kara ağacı ya da regresyon modeli ile veri tahmin edilebilir.

#### **5.1.2 Veri Dönüştürme**

Makine öğrenimi algoritmaları sayısal verilerle çalışır. Bu nedenle kategorik verileri sayısal veriye dönüştürmek gerekir. Bu dönüşüm için iki yöntem vardır [20].

##### **5.1.2.1 Etiket Kodlama (Label Encoding)**

Her bir değere sayısal olarak bir temsil atanır. Etiket kodlama genellikle aralarında sayısal sıralamanın yapılabileceği sınıflar arasından seçilir. Bu da aralarında sıralama yapılamayan sınıflar için sorun teşkil etmektedir.

İsim	Yaş	Cinsiyet		İsim	Yaş	Cinsiyet
A	25	Erkek	→	A	25	1
B	27	Erkek		B	27	1
C	32	Kadın		C	32	0

**Şekil 5.** Etiket kodlamaya bir örnek [20]

### 5.1.2.2 One-Hot Kodlama

Etiket kodlamasındaki “aralarında sıralama yapılamayan sınıflar” sorununa çözüm getiren One-Hot encoding, sınıflar arasındaki sıralamayla değil varlık ya da yokluklarıyla ilgilenir [8].

İsim	Yaş	Cinsiyet		A	B	C	Yaş	Cinsiyet
A	25	Erkek	→	1	0	0	25	1
B	27	Erkek		0	1	0	27	1
C	32	Kadın		0	0	1	32	0

**Şekil 6.** One-Hot kodlamaya bir örnek [20]

## 5.2 Eğitim Ve Test Setinin Oluşturulması

Oluşturulan modelde veri setini farklı verilerle eğitmek modelin geçerliliği açısından önemlidir. Sadece tek bir setle öğretilen model aşırı öğrenmeye (overfitting) neden olabilmektedir. Bu nedenle modeli eğitim ve test setlerine bölmek gerekir. Eğitim bölümünde model eğitilirken, test verisinde modelin başarımı ölçülür [8].

## 5.3 Veri Ölçeklendirme

Sayısal veriler birbirleriyle benzer skalada bulunmayabilirler. Söz gelimi, insan yaşı genellikle 1’den 100’e kadar ifade edilirken, bir muhabbet kuşunun yaşı genellikle 1 ile 15 arası ifade edilir. Bu veriler farklı aralıkta olduğu için verini ölçeklendirilmesi gerekir.

### 5.3.1 Min – Max Normalizasyonu

Bu yöntemde verilerin en küçüğü 0, en büyüğü ise 1 olarak seçilir. Kalanlara ise 0 – 1 aralığında normalizasyon işlemi yapılır [20].

$$X_n = \frac{X - X_{min}}{X_{max} - X_{min}}$$

## 6. PERFORMANS DEĞERLENDİRME ÖLÇÜTLERİ

Makine öğrenmesi modelinde başarıyı ölçmek için performans değerlendirme ölçütlerine ihtiyaç duyulur. Bu modelin iyi bir model olup olmadığını ölçmeye yarar. Bu bölümde tezde kullanılan performans değerlendirme ölçütlerine yer verilecektir.

### 6.1 Ortalama Mutlak Hata (Mean Absolute Error, MAE)

Ortalama mutlak hata, veri setindeki gerçek değerler ile tahmin değerlerinin arasındaki farkın mutlak değerinin toplamı alınarak sonucun örnek sayısına bölünmesidir. 0 ile  $\infty$  arasında değer alır ve bu değer ne kadar küçük olursa model için o kadar iyi performans elde edilmiş olur [8].

$$MAE(y, h_{\theta}(x)) = \frac{1}{n} \sum_{i=0}^{n-1} |y_i - h_{\theta}(x_i)|$$

### 6.2 Ortalama Kare Hata (Means Squared Error, MSE)

Veri setinden gerçek değerler ile tahmin değerlerinin farklarının karelerinin toplamı alınır ve çıkan sonucun örnek sayısına bölünmesi ile elde edilir. 0 ile  $\infty$  arasında değer ne kadar küçük olursa model için o kadar iyi performans elde edilmiş olur [8].

$$MSE(y, h_{\theta}(x)) = \frac{1}{n} \sum_{i=0}^{n-1} (y_i - h_{\theta}(x_i))^2$$

### 6.3 Ortalama Kare Hata Karekökü (Root Means Squared Error, RMSE)

Ortalama kare hatasının karesinin alınmasıyla elde edilir. Aynı şekilde burada da değer 0'dan  $\infty$ 'a değer alır ve bu değer ne kadar küçük olması modelin performansının yüksek olduğu anlamına gelir [8].

$$RMSE(y, h_{\theta}(x)) = \sqrt{\frac{1}{n} \sum_{i=0}^{n-1} (y_i - h_{\theta}(x_i))^2}$$

### 6.4 Medyan Mutlak Hata (Median Absolute Error, MedAE)

Veri setindeki gerçek ile tahmin değerleri arasındaki bütün mutlak farkların medyanının alınmasıdır. 0 ile  $\infty$  arasında değer alır ve bu değer ne kadar küçük olursa model için o kadar iyi performans elde edilmiş olur [8].

$$MedAE(y, h_{\theta}(x)) = \text{Medyan}(|y_1 - h_{\theta}(x_1)|, \dots, |y_n - h_{\theta}(x_n)|)$$

### 6.5 Belirleme Katsayısı (Determination Coefficient, R-Squared)

Kesişimli (regressors) bir modelde belirleme katsayısı, gözlemlenen sonuçlar ve tahminler arasındaki korelasyon katsayısının karesidir [21]. Veri setinde yer almayan örneklerin model tarafından ne kadar iyi tahmin edileceğinin ölçüsüdür. 0 ile 1 arasında bir değer alır. Bu değer 1'e ne kadar yakınsa modelin tahmin performansı o kadar iyidir [8].

$$R^2(y, h_{\theta}(x)) = 1 - \frac{\sum_{i=0}^{n-1} (y_i - h_{\theta}(x_i))^2}{\sum_{i=0}^{n-1} (y_i - \frac{1}{n} \sum_{i=1}^n y_i)^2}$$

## **7. KULLANILAN VERİLER**

### **7.1 COVID-19**

Bu çalışma da COVID-19 enfekte verileri kullanılmıştır.

#### **7.1.1 Verileri Elde Etme**

COVID-19 verileri “Apify” adlı siteden “Coronavirus stats in Turkey” API’ı kullanılarak JSON formatında alınmıştır.

#### **7.1.2 Seçilen Tarih Aralığı**

Başlangıç olarak COVID-19’un Türkiye’de ilk görüldüğü tarih olan 11 Mart 2020 tarihi seçilmiştir. Son tarih olaraksa 2020 yılının son günü olan 31 Aralık tarihi seçilmiştir. Böylelikle veriler sadece 2020 yılını kapsamaktadır.

### **7.2 Hava Kalitesi**

Bu çalışma da PM10 sayısal değeri kullanılmıştır. PM10 değeri arttıkça hava kalitesi düşmektedir, azaldıkça hava kalitesi artmaktadır.

#### **7.2.1 Verileri Elde Etme**

Hava kalitesi verileri Çevre ve Şehircilik Bakanlığı Hava Kalitesi Veri Bankası’ndan Excel formatıyla (.xlsx) kirleticilerle, belirli zaman aralığında ve il il elde edilmiştir.

#### **7.2.2 Seçilen Tarih Aralığı Ve İller**

Verilerin başlangıç tarihi Covid-19’un Türkiye’de ilk görülmeye başlandığı tarih olan 11 Mart 2020’dir. Son tarih ise 2020 yılının sonu olan 31 Aralık 2020’dir. Sağlık Bakanlığı verileri 2020 yılında Türkiye geneli yayınlamıştır. Bu nedenle elde edilen hava kalitesi verileri tüm illeri ve illerin merkezlerini kapsamaktadır.



### 7.2.3 Kirleticilerin Çeşitleri

Hava kalitesi verilerinde 6 adet kirletici çeşiti vardır. Bunlar PM10 (  $\mu\text{g}/\text{m}^3$  ), SO2 (  $\mu\text{g}/\text{m}^3$  ), CO (  $\mu\text{g}/\text{m}^3$  ), NO2 (  $\mu\text{g}/\text{m}^3$  ), NOX (  $\mu\text{g}/\text{m}^3$  ), O3 (  $\mu\text{g}/\text{m}^3$  )'dur. Aralarından en fazla ilde (79 il) ölçümü yapılan kirletici çeşiti PM10 (  $\mu\text{g}/\text{m}^3$  )'dur.

### 7.2.4 Verilerin Düzenlenmesi

İl il elde edilen kirletici verilerinin önce günlere göre ortalaması alınmıştır. Sonra günlere göre il il elde edilen ortalamanın Türkiye geneli olması için ortalaması alınmıştır.

### 7.2.5 Hava Kalitesi İndeksi

Hava kalitesi indeksi kirletici çeşitlerinden biriyle yapılan ölçümle elde edilen yerdeki hava kalitesini ölçen indekstir. Çeşitli yöntemlerle ölçülen kirleticileri tek bir parametreye indirir. Birçok devletin ve kurumun (AB) kendi kalite indeks standardı vardır. Bu çalışmada Türkiye, Avrupa Çevre Ajansı'na üye olduğu için Avrupa Çevre Ajansı'nın hava kalite indeksi kullanılmıştır. Hava kalite indeksi PM10 değerinde göre İyi, Makul, Orta, Kötü, Çok Kötü ve Aşırı Kötü olarak sınıflandırılır.<sup>1</sup>

## 8. TESTLER VE BULGULAR

Bu bölümde tezin amacı ile konusu doğrultusunda ve model geliştirme sürecine uygun olacak şekilde model oluşturulmuş, bu model bağımsız değişken olarak hava kirliliği (PM10) verileri, bağımlı değişken olarak ise Covid-19 enfekte verileri mevsimsel olarak (yaz – kış) ayrılıp kullanılarak doğrusal regresyon, destek vektör regresyon, yapay sinir ağları ve LSTM teknikleri üzerinde test edilmiştir. Bu modelin test işlemlerinden sonra performans değerlendirme kriterleri ile bulgular elde edilmiş ve değerlendirilmiştir.


### 8.1 Doğrusal Regresyon (DR)

---

1 <https://airindex.eea.europa.eu/Map/AQI/Viewer/#>


### 8.1.1 Kış Verileriyle Modelin Testi

#### Eğitim Veri Seti



Şekil 7. DR kış eğitim verileri modelinin öğrenme eğrisi

#### Test Veri Seti



Şekil 8. DR kış test verileri modelinin öğrenme eğrisi

Bu doğrusal regresyon analizlerinde y bağımlı değişken olarak kış COVID-19 enfekte verileri, x bağımsız değişken olarak kış hava kirliliği (PM10) verileri kullanılmıştır. Veriler modelde kullanmadan önce minimum-maksimum normalizasyonu kullanılarak verileri 0-1 aralığına ölçeklendirilmiştir. Elde edilen regresyon modelinde denklemi şu şekildedir:

Elde edilen regresyon modeli:  $Y = [0.09671608] + [0.24603169]X$

#### **8.1.1.1 Modelin Performans Ölçümü**

##### **Test**

R-Kare: -0.0443 (1'e yakın daha iyi)

MAE: 0.2381 (0'a yakın daha iyi)

MSE: 0.0931 (0'a yakın daha iyi)

RMSE: 0.3052 (0'a yakın daha iyi)

MedAE: 0.1715 (0'a yakın daha iyi)

##### **Eğitim**

R-Kare: 0.0294 (1'e yakın daha iyi)

MAE: 0.2447 (0'a yakın daha iyi)


MSE: 0.1051 (0'a yakın daha iyi)

RMSE: 0.3242 (0'a yakın daha iyi)

MedAE: 0.1705 (0'a yakın daha iyi)


#### **8.1.2 Yaz Verileriyle Modelin Testi**

##### **Eğitim Veri Seti**



Şekil 9. DR yaz eğitim verileri modelinin öğrenme eğrisi

## Test Veri Seti



Şekil 10. DR yaz test verileri modelinin öğrenme eğrisi

Bu doğrusal regresyon analizlerinde y bağımlı değişken olarak yaz COVID-19 enfekte verileri, x bağımsız değişken olarak yaz hava kirliliği (PM10) verileri kullanılmıştır. Veriler modelde kullanmadan önce minimum-maksimum normalizasyonu kullanılarak verileri 0-1 aralığına ölçeklendirilmiştir. Elde edilen regresyon modelinde denklemi şu şekildedir:

Elde edilen regresyon modeli:  $Y = [0.38315004] + [0.25217243]X$

### **8.1.2.1 Modelin Performans Ölçümü**

#### **Test**

R-Kare: -0.0752 (1'e yakın daha iyi)

MAE: 0.2415 (0'a yakın daha iyi)

MSE: 0.0878 (0'a yakın daha iyi)

RMSE: 0.2962 (0'a yakın daha iyi)

MedAE: 0.2198 (0'a yakın daha iyi)

#### **Eğitim**

R-Kare: 0.0311 (1'e yakın daha iyi)

MAE: 0.2394 (0'a yakın daha iyi)

MSE: 0.0803 (0'a yakın daha iyi)


RMSE: 0.2833 (0'a yakın daha iyi)

MedAE: 0.2254 (0'a yakın daha iyi)

## **8.2 Destek Vektör Regresyonu (DVR)**


### **8.2.1 Kış Verileriyle Modelin Testi**

## Eğitim Veri Seti



Şekil 11. DVR kış eğitim verileri modelinin öğrenme eğrisi

## Test Veri Seti



Şekil 12. DVR kış test verileri modelinin öğrenme eğrisi

Bu destek vektör regresyon analizlerinde y bağımlı değişken olarak kış COVID-19 enfekte verileri, x bağımsız değişken olarak kış hava kirliliği (PM10) verileri kullanılmıştır. Veriler modelde kullanmadan önce minimum-maksimum normalizasyonu kullanılarak verileri 0-1 aralığına ölçeklendirilmiştir. Elde edilen destek destek vektör regresyon modelinde denklemi şu şekildedir:

#### **8.2.1.1 Modelin Performans Ölçümü**

##### **Test**

R-Kare: -0.0114 (1'e yakın daha iyi)

MAE: 0.1715 (0'a yakın daha iyi)

MSE: 0.0902 (0'a yakın daha iyi)

RMSE: 0.3003 (0'a yakın daha iyi)

MedAE: 0.0881 (0'a yakın daha iyi)

##### **Eğitim**

R-Kare: -0.0471 (1'e yakın daha iyi)

MAE: 0.1976 (0'a yakın daha iyi)


MSE: 0.1134 (0'a yakın daha iyi)

RMSE: 0.3368 (0'a yakın daha iyi)

MedAE: 0.0889 (0'a yakın daha iyi)


#### **8.2.2 Yaz Verileriyle Modelin Testi**

##### **Eğitim Veri Seti**



Şekil 13. DVR yaz eğitim verileri modelinin öğrenme eğrisi

#### Test Veri Seti



Şekil 14. DVR yaz test verileri modelinin öğrenme eğrisi

Bu destek vektör regresyon analizlerinde y bağımlı değişken olarak yaz COVID-19 enfekte verileri, x bağımsız değişken olarak yaz hava kirliliği (PM10) verileri kullanılmıştır. Veriler modelde kullanmadan



önce minimum-maksimum normalizasyonu kullanılarak verileri 0-1 aralığına ölçeklendirilmiştir. Elde edilen destek vektör regresyon modelinde denklemi şu şekildedir:

### **8.2.2.1 Modelin Performans Ölçümü**

#### **Test**

R-Kare: -0.0043 (1'e yakın daha iyi)

MAE: 0.2383 (0'a yakın daha iyi)

MSE: 0.0820 (0'a yakın daha iyi)

RMSE: 0.2863 (0'a yakın daha iyi)

MedAE: 0.2332 (0'a yakın daha iyi)

#### **Eğitim**

R-Kare: 0.0422 (1'e yakın daha iyi)

MAE: 0.2393 (0'a yakın daha iyi)


MSE: 0.0794 (0'a yakın daha iyi)

RMSE: 0.2817 (0'a yakın daha iyi)

MedAE: 0.2203 (0'a yakın daha iyi)

## **8.3 Yapay Sinir Ağları**


### **8.3.1 Kış Verileriyle Modelin Testi**



**Şekil 15.** YSA kış verisi modelinin öğrenme eğrisi

Bu yapay sinir ağları modelinde y bağımlı değişken olarak kış COVID-19 enfekte verileri, x bağımsız değişken olarak kış hava kirliliği (PM10) verileri kullanılmıştır. Veriler modelde kullanmadan önce minimum-maksimum normalizasyonu kullanılarak verileri 0-1 aralığına ölçeklendirilmiştir. Bu modelde 84 tane eğitim verisi 37 tane test verisi olmak üzere toplam 121 adet veri vardır. Yapılan denemeler sonucu modele, 2 tane katman eklenmiştir ve nöron sayısı 8 olarak belirlenmiştir. Bu katmanlarda doğrusal olmayan “Rectified Linear Unit (ReLU)” aktivasyon fonksiyonu kullanılmıştır. Initializers olarak “HeUniform” fonksiyonu kullanılmıştır. Ardından hesaplama aşamasında hesaplama açısından verimli ve küçük hafıza gereksinimi olduğu için “Adam” optimizasyon algoritması, kayıp değerler içinse “Mean Squared Error (MSE)” metriği kullanılmıştır. Girişte ağı gösterilecek örnek sayısı olan “batch\_size” ise 12 olarak, tekrar sayısı olan “epochs” ise 150 olarak belirlenmiştir.

### 8.3.2 Yaz Verileriyle Modelin Testi



**Şekil 16.** YSA yaz verisi modelinin öğrenme eğrisi

Bu yapay sinir ağları modelinde y bağımlı değişken olarak yaz COVID-19 enfekte verileri, x bağımsız değişken olarak yaz hava kirliliği (PM10) verileri kullanılmıştır. Veriler modelde kullanmadan önce minimum-maksimum normalizasyonu kullanılarak verileri 0-1 aralığına ölçeklendirilmiştir. Bu modelde 63 tane eğitim verisi 28 tane test verisi olmak üzere toplam 91 adet veri vardır. Yapılan denemeler sonucu modele, 2 tane katman eklenmiştir ve nöron sayısı 8 olarak belirlenmiştir. Bu katmanlarda doğrusal olmayan “Rectified Linear Unit (ReLU)” aktivasyon fonksiyonu kullanılmıştır. Initializers olarak “HeUniform” fonksiyonu kullanılmıştır. Ardından hesaplama aşamasında hesaplama açısından verimli ve küçük hafıza gereksinimi olduğu için “Adam” optimizasyon algoritması, kayıp değerler içinse “Mean Squared Error (MSE)” metriği kullanılmıştır. Girişte ağa gösterilecek örnek sayısı olan “batch\_size” ise 12 olarak, tekrar sayısı olan “epochs” ise 150 olarak belirlenmiştir.

### 8.3.3 Modelin Performansı

#### Hata Ölçüm Metrikleriyle

#### Kış

R-Kare: -0.0225 (1'e yakın daha iyi)

MAE: 0.2349 (0'a yakın daha iyi)

MSE: 0.0912 (0'a yakın daha iyi)

RMSE 0.3019 (0'a yakın daha iyi)

MedAE: 0.1642 (0'a yakın daha iyi)

## **Yaz**

R-Kare: 0.0016 (1'e yakın daha iyi)

MAE: 0.2357 (0'a yakın daha iyi)

MSE: 0.0815 (0'a yakın daha iyi)

RMSE: 0.2855 (0'a yakın daha iyi)

MedAE: 0.2112 (0'a yakın daha iyi)


## **Öğrenme Eğrisiyle**

Bir öğrenme eğrisinin şekli ve dinamiği derin öğrenme modelinin performansı hakkında bilgi verir. Y eksenindeki düşük değerler görece daha iyi bir model performansına işaret eder. Üç ortak dinamik şu şekildedir:<sup>2</sup>

### **1. Uyumsuz(Underfit)**


---

2 <https://machinelearningmastery.com/learning-curves-for-diagnosing-machine-learning-model-performance/>




Şekil 17. Uyumsuz (underfit) eğrisi

## 2. Aşırı Uyum (Overfitting)



Şekil 18. Aşırı uyum (overfitting) eğrisi

## 3. İyi Uyum (Good Fit)




**Şekil 19.** İyi uyum eğrisi (good fit)

### 8.3.4 Değerlendirme

Görüldüğü üzere eğitilen modellerde 3. modele (Good Fit) daha yakın durmaktadır. Bu model eğitim setini iyi öğrenmiş bir modele işaret eder. Daha farklı denemelerle daha da iyileştirilebilir.

## 8.4 LSTM


### 8.4.1 Kış Verileriyle Modelin Testi



**Şekil 20.** LSTM kış verisi modelinin öğrenme eğrisi

Buradaki yinelenen sinir ağılar mimarisindeki LSTM modelinde y bağımlı değişken olarak yaz COVID-19 enfekte verileri, x bağımsız değişken olarak yaz hava kirliliği (PM10) verileri kullanılmıştır. Veriler modelde kullanmadan önce minimum-maksimum normalizasyonu kullanılarak verileri 0-1 aralığına ölçeklendirilmiştir. Bu modelde 63 tane eğitim verisi 28 tane test verisi olmak üzere toplam 91 adet veri vardır. Yapılan denemeler sonucu modele, 2 tane katman eklenmiştir ve nöron sayısı ilk katmanda 6, ikinci katmanda 4 olarak belirlenmiştir. Bu katmanlarda doğrusal olmayan “Hyperbolic Tangen (tanh)” aktivasyon fonksiyonu kullanılmıştır. Initializers olarak “Xavier ” fonksiyonu kullanılmıştır. Katmanların arasında aşırı uyumu engelleyebilmek adına rate’i 0 olan noise\_shape’i 2 olan Dropout katmanı eklenmiştir. Ardından hesaplama aşamasında hesaplama açısından verimli ve küçük hafıza gereksinimi olduğu için “Adam” optimizasyon algoritması, kayıp değerler içinse “Mean Squared Error (MSE)” metriği kullanılmıştır. Girişte ağa gösterilecek örnek sayısı olan “batch\_size” ise 4 olarak, tekrar sayısı olan “epochs” ise 75 olarak belirlenmiştir.

#### 8.4.2 Yaz Verileriyle Modelin Testi



**Şekil 21.** LSTM yaz verisi modelinin öğrenme eğrisi

Buradaki yinelenen sinir ağılar mimarisindeki LSTM modelinde y bağımlı değişken olarak yaz COVID-19 enfekte verileri, x bağımsız değişken olarak yaz hava kirliliği (PM10) verileri kullanılmıştır. Veriler modelde kullanmadan önce minimum-maksimum normalizasyonu kullanılarak verileri 0-1 aralığına ölçeklendirilmiştir. Bu modelde 63 tane eğitim verisi 28 tane test verisi olmak üzere toplam 91 adet veri vardır. Yapılan denemeler sonucu modele, 2 tane katman eklenmiştir ve nöron sayısı ilk katmanda 6, ikinci katmanda 4 olarak belirlenmiştir. Bu katmanlarda doğrusal olmayan “Hyperbolic Tangen (tanh)” aktivasyon fonksiyonu kullanılmıştır. Initializers olarak “Xavier ” fonksiyonu kullanılmıştır. Katmanların arasında aşırı uyumu engelleyebilmek adına rate’i 0 olan noise\_shape’i 2 olan Dropout katmanı eklenmiştir. Ardından hesaplama aşamasında hesaplama açısından verimli ve küçük hafıza gereksinimi olduğu için “Adam” optimizasyon algoritması, kayıp değerler içinse “Mean Squared Error (MSE)” metriği kullanılmıştır. Girişte ağı gösterilecek örnek sayısı olan “batch\_size” ise 4 olarak, tekrar sayısı olan “epochs” ise 150 olarak belirlenmiştir.

#### **8.4.3 Modelin Performansı**

##### **Hata Ölçüm Metrikleriyle**

###### **Kış**

R-Kare: -0.0147 (1’e yakın daha iyi)

MAE: 0.2301 (0’a yakın daha iyi)

MSE: 0.0905 (0’a yakın daha iyi)

RMSE: 0.3008 (0’a yakın daha iyi)

MedAE: 0.1726 (0’a yakın daha iyi)

###### **Yaz**

R-Kare: -0.0220 (1’e yakın daha iyi)

MAE: 0.2382 (0’a yakın daha iyi)

MSE: 0.0834 (0’a yakın daha iyi)

RMSE: 0.2888 (0’a yakın daha iyi)




MedAE: 0.2280 (0'a yakın daha iyi)

## Öğrenme Eğrisiyle

Bir öğrenme eğrisinin şekli ve dinamiği derin öğrenme modelinin performansı hakkında bilgi verir. Y eksenindeki düşük değerler görece daha iyi bir model performansına işaret eder. Burada ayrıca bir eğriye değinilecektir<sup>3</sup>.

### 1. Temsili Olmayan Doğrulama Veri Seti (Unrepresentative Validation Dataset)



Şekil 22. Temsili olmayan doğrulama veri seti öğrenme eğrisi

### 8.4.4 Değerlendirme

Görüldüğü üzere eğitilen modelde Temsili Olmayan Doğrulama Veri Setine (Unrepresentative Validation Dataset) daha yakın durmaktadır. Bu model doğrulama veri setini eğitim veri setinden daha doğru tahminleyebilir.

<sup>3</sup> <https://machinelearningmastery.com/learning-curves-for-diagnosing-machine-learning-model-performance/>

## 9. SONUÇ VE KARŞILAŞTIRMA

Çizelge (10.1)' de ve Çizelge (10.2)' de veri setini dönemlere ayırıp, regresyon modelinde ayrıca veri setini test ve eğitim setlerine ayırıp, seçilen teknikler üzerinde test edilmiştir ve modelin performans skorları elde edilmiştir.

**Çizelge 9.1** Regresyonlar için modellerin ortalama performans skorları

Teknik	Dönem	Test-Eğitim	R-Kare	MAE	MSE	RMSE	MedAE
DR	Kış	Test	-0.0443	0.2381	0.0931	0.3052	0.1715
		Eğitim	0.0294	0.2447	0.1051	0.3242	0.1705
	Yaz	Test	-0.0752	0.2415	0.0878	0.2962	0.2198
		Eğitim	0.0311	0.2394	0.0803	0.2833	0.2254
DVR	Kış	Test	-0.0114	0.1715	0.0902	0.3003	0.0881
		Eğitim	-0.0471	0.1976	0.1134	0.3368	0.0889
	Yaz	Test	-0.0043	0.2383	0.0820	0.2863	0.2332
		Eğitim	0.0422	0.2393	0.0794	0.2817	0.2203

**Çizelge 9.2** YSA ve LSTM modellerinin ortalama performans skorları

Teknik	Dönem	R-Kare	MAE	MSE	RMSE	MedAE
YSA	Kış	-0.0225	0.2349	0.0912	0.3019	0.1642
	Yaz	0.0016	0.2357	0.0815	0.2855	0.2112
LSTM	Kış	-0.0147	0.2301	0.0905	0.3008	0.1726
	Yaz	-0.0220	0.2382	0.0834	0.2888	0.2280

Sonuçlar 4 basamağa kadar yuvarlanma sonucunda elde edilmiştir. Sonuçların iki farklı tabloya ayrılmasının nedeni Çizelge (10.1)' de regresyon teknikleri olması ve Çizelge (10.2)' de yapay öğrenme teknikleri olmasıdır. Böylece benzer tekniklerin birbirleriyle karşılaştırmaları daha anlamlı olacaktır.

Genel olarak her dört modelde de R-Kare skorları eğitim ile test veri setleri arasında ilişkide anlamlı sonuç bulamamıştır. Diğer skorlara baktığımızda Çizelge (10.1)'de yaz döneminde ve eğitim setinde destek vektör regresyonu, yaz döneminde ve test setinde destek vektör regresyonu, kış döneminde ve eğitim setinde destek vektör regresyonu, kış döneminde ve test setinde destek vektör regresyonu modeli daha iyi skorlar elde etmiştir. Çizelge (10.2)'ye baktığımızda ise yaz döneminde yapay sinir ağları, kış döneminde LSTM modeli daha iyi skorlar elde etmiştir.

Bu veri seti için Çizelge (10.1)'de destek vektör regresyonu daha iyi performans vermiştir. Çizelge (10.2)'ye bakıldığında ise yaz döneminde yapay sinir ağları, kış döneminde ise LSTM modelleri daha iyi sonuç vermiştir. Sonuçların birbirine yakın çıkmasının nedeni veri sayısının yeterince yüksek olmamasından kaynaklanıyor olabilir. 2021 yılındaki COVID-19 enfekte sayılarını katarak daha iyi bir sonuç elde edilebilir. Ayrıca bağımsız değişken tek değişkenden oluşmaktadır, bu çalışma için farklı meteorolojik veriler gibi daha fazla değişken eklenebilir.

## EKLER

### EK A YSA Modelinin Ağırlıkları

1. Gizli Katmana Ait Nöronlar									
Yaz-İlk-Katman	Nöron 1	Nöron 2	Nöron 3	Nöron 4	Nöron 5	Nöron 6	Nöron 7	Nöron 8	
Girdi 1	1.35207	-1.82177	1.9926	0.689688	-1.25199	1.98647	0.359718	-0.954108	
BIAS 1									
	-0.233866								
	0								
	-0.00802272								
	-0.0789203								
	0								
	0.139892								

		-0.0628785							
		0							
	<b>2. Gizli Katmana Ait Nöronlar</b>								
<b>1. Gizli Katmana Ait Nöronlar</b>	<b>Yaz-İkinci-Katman</b>	<b>Nöron 1</b>	<b>Nöron 2</b>	<b>Nöron 3</b>	<b>Nöron 4</b>	<b>Nöron 5</b>	<b>Nöron 6</b>	<b>Nöron 7</b>	<b>Nöron 8</b>
	<b>Nöron 1</b>	0.428397	0.137296	0.643256	0.55532	-0.565964	0.34609	-0.0325942	0.620256
	<b>Nöron 2</b>	-0.657422	-0.34483	-0.670253	0.587191	0.659659	-0.200679	-0.823024	-0.666868
	<b>Nöron 3</b>	-0.199152	-0.400498	-0.149982	0.45155	-0.551164	-0.650146	0.524873	0.0960774
	<b>Nöron 4</b>	-0.0638911	-0.2625	0.789025	0.353121	-0.385523	0.327503	-0.43783	0.298006
	<b>Nöron 5</b>	-0.305512	-0.220751	0.613841	0.645245	0.294401	-0.135033	0.30594	0.770709
	<b>Nöron 6</b>	-0.830617	0.187378	0.694746	-0.63068	-0.0557024	-0.531058	0.639258	-0.76047
	<b>Nöron 7</b>	-0.153048	0.325028	0.366682	0.0261303	0.694978	-0.224761	0.320222	0.0556545
	<b>Nöron 8</b>	0.407371	0.652301	-0.192443	-0.865682	0.517263	-0.615539	0.843421	-0.14441
	<b>BIAS 2</b>								
		0							
		0							
		-0.0458551							
		-0.124967							
		0							
		0							
		0.0383156							

2. Gizli Katmana Ait Nöronlar		0							
		0							
	Yaz-Çıktı- Katman	Çıktı Katmanı Nöronu							
	Nöron 1	-0.365276							
	Nöron 2	-0.424146							
	Nöron 3	0.712434							
	Nöron 4	-0.502065							
	Nöron 5	-0.106324							
	Nöron 6	0.545054							
	Nöron 7	-0.632436							
	Nöron 8	0.690564							
	BIAS 3								
		-0.0419456							

1. Gizli Katmana Ait Nöronlar									
Kış-İlk- Katman	Nöron 1	Nöron 2	Nöron 3	Nöron 4	Nöron 5	Nöron 6	Nöron 7	Nöron 8	
Girdi Nöronu	0.319402	-1.51236	2.2947	1.08355	0.274436	0.936134	-0.350218	0.346565	
BIAS	0.277852								
	0								
	-0.163307								

		0.301239							
		-0.0809254							
		0							
		0							
		0							
<b>2. Gizli Katmana Ait Nöronlar</b>									
<b>1. Gizli Katmana Ait Nöronlar</b>	<b>Kış-İkinci-Katman</b>	<b>Nöron 1</b>	<b>Nöron 2</b>	<b>Nöron 3</b>	<b>Nöron 4</b>	<b>Nöron 5</b>	<b>Nöron 6</b>	<b>Nöron 7</b>	<b>Nöron 8</b>
	<b>Nöron 1</b>	0.0245982	0.982011	0.515221	0.297438	0.824151	0.796975	-0.0284847	0.740544
	<b>Nöron 2</b>	-0.809403	0.0634158	0.0902522	0.810406	0.816152	-0.55638	0.119049	0.378585
	<b>Nöron 3</b>	-0.331874	-0.21676	-0.550415	0.642461	0.593638	0.212725	-0.142395	0.580418
	<b>Nöron 4</b>	-0.816735	0.421193	0.301741	0.786728	0.299012	0.414233	-0.550232	0.111099
	<b>Nöron 5</b>	0.119399	-0.669477	0.589924	0.874278	0.272582	0.705732	-0.0500324	0.603943
	<b>Nöron 6</b>	-0.471055	-0.172563	-0.120977	0.218148	0.738409	0.481968	0.198444	0.10084
	<b>Nöron 7</b>	-0.412754	0.687506	0.786554	0.176695	0.544481	0.122754	0.00517803	0.778801
	<b>Nöron 8</b>	0.264062	-0.842602	0.358622	0.767428	0.747621	0.121035	-0.0522491	-0.58681
	<b>BIAS</b>								
		-0.00534103							
		0.322851							

		0.354794							
		-0.130126							
		-0.149614							
		-0.0824202							
		0							
		-0.148249							
2. Gizli Katmana Ait Nöronlar	Kış-Çıktı-Katman Nöron	Çıktı							
	Nöron 1	0.152145							
	Nöron 2	-1.0475							
	Nöron 3	-1.12867							
	Nöron 4	0.253723							
	Nöron 5	0.332625							
	Nöron 6	0.00613492							
	Nöron 7	-0.34777							
	Nöron 8	0.364328							
	BIAS								
		-0.203278							

### EK B LSTM Modelinin Ağırlıkları

<i>Kış – İlk Kat- man</i>																								
	<i>Nö- ron 1</i>	<i>Nö- ron 2</i>	<i>Nö- ron 3</i>	<i>Nö- ron 4</i>	<i>Nö- ron 5</i>	<i>Nö- ron 6</i>	<i>Nö- ron 7</i>	<i>Nö- ron 8</i>	<i>Nö- ron 9</i>	<i>Nö- ron 10</i>	<i>Nö- ron 11</i>	<i>Nö- ron 12</i>	<i>Nö- ron 13</i>	<i>Nö- ron 14</i>	<i>Nö- ron 15</i>	<i>Nö- ron 16</i>	<i>Nö- ron 17</i>	<i>Nö- ron 18</i>	<i>Nö- ron 19</i>	<i>Nö- ron 20</i>	<i>Nö- ron 21</i>	<i>Nö- ron 22</i>	<i>Nö- ron 23</i>	<i>Nö- ron 24</i>

<b>Gir di Nö- ron u</b>	0.2 453 42	0.30 654 5	0.20 381 3	0.64 750 5	0.24 167 2	- 0.26 506 4	0.38 964	- 0.44 170 1	0.24 093 1	0.32 980 8	0.05 073 06	- 0.07 304 27	- 0.18 549 1	0.22 888 1	- 0.34 133	- 0.43 705 6	0.31 104 5	- 0.08 346 34	- 0.52 758 3	- 0.14 746 6	0.24 449 9	0.15 389 7	0.54 755 7	- 0.18 860 7
<b>Nö- ron 1</b>	- 0.0 858 216	- 0.10 540 6	0.17 673 5	- 0.24 618 6	0.05 574 58	- 0.20 958 5	0.12 032 4	- 0.15 765 5	- 0.40 866 3	0.14 895 5	- 0.04 089 69	0.00 759 208	- 0.04 752 24	0.41 672 4	0.26 333 3	- 0.13 496 1	0.06 306 04	- 0.00 524 416	- 0.13 087 6	- 0.36 418 4	0.34 619 7	- 0.06 522 1	0.20 257 2	- 0.17 324
<b>Nö- ron 2</b>	- 0.0 625 852	0.31 309 8	- 0.05 480 5	- 0.18 356 2	0.00 292 153	0.04 829 22	- 0.02 736 41	- 0.47 745 6	0.42 726 6	0.35 119 6	- 0.19 429 4	0.29 546 5	- 0.06 310 39	0.02 322 86	0.10 212 1	- 0.06 845 84	0.10 466 4	0.26 762 6	0.05 312 41	- 0.16 412 3	0.01 511 65	0.22 778 8	0.04 364 53	- 0.11 561 1
<b>Nö- ron 3</b>	- 0.1 687 85	0.03 449 67	0.31 247 5	- 0.18 203	0.18 835 8	- 0.02 774 39	0.20 167 7	- 0.04 973 8	0.02 932 98	- 0.26 659 6	0.15 099 4	0.17 029	0.13 747 3	- 0.24 976 3	0.14 982 3	- 0.51 500 2	0.17 285 8	0.10 430 3	0.40 786 8	- 0.13 131 2	0.09 728 15	- 0.09 164 59	0.05 652 13	0.11 821 1
<b>Nö- ron 4</b>	0.1 198 73	- 0.16 466 2	- 0.35 394	- 0.16 584 2	0.16 575 6	- 0.09 672 77	0.13 486 5	0.31 901 5	0.08 847 53	- 0.23 326 5	- 0.37 085 3	0.04 987 71	- 0.19 946 4	0.09 906 02	0.44 837 2	0.00 332 55	- 0.15 487 2	0.33 741 1	0.00 787 192	- 0.04 139 07	0.06 841 98	0.17 213 5	- 0.12 483 5	0.08 086 66
<b>Nö- ron 5</b>	0.0 555 78	0.23 738 6	0.34 565 1	- 0.30 644	0.16 982 7	- 0.19 178 9	0.04 473 1	0.10 269 7	- 0.17 140 3	- 0.01 563 43	0.31 059 4	0.37 848 9	0.36 787 6	- 0.17 259 7	0.13 432 2	0.16 305 3	0.07 043 37	0.26 668 8	- 0.02 490 04	0.19 660 7	- 0.17 246	0.01 547 53	- 0.09 345 83	0.12 584
<b>Nö- ron 6</b>	0.0 640 971	0.04 037 17	- 0.11 936 5	- 0.25 578 8	0.14 085 5	- 0.38 386 4	0.09 694 46	0.18 528 5	0.28 619	- 0.21 472 1	0.13 904 3	0.00 204 323	- 0.09 568 49	0.09 695 18	0.42 758 9	- 0.19 288 3	0.18 034 8	0.25 885 8	- 0.04 583 8	- 0.33 058	- 0.06 831 37	0.10 218 6	0.12 766 9	0.27 459 4
<b>BIA S</b>																								
	- 0.1 195 13																							
	0.1 693 7																							
	- 0.0 246 563																							
	0.1 340 32																							
	0.1 127 3																							
	- 0.1																							



	313 5																					
	1																					
	1																					
	1																					
	1																					
	1																					
	1																					
	0.0 758 499																					
	- 0.0 886 782																					
	0.0 885 482																					
	- 0.0 364 094																					
	0.0 036 076 3																					
	0.0 598 466																					
	- 0.1 182 94																					
	0.1 701 58																					
	- 0.0 245 769																					
	0.1 612 93																					
	0.1 015 12																					
	- 0.1 320 96																					

[illegible]

	0.1 921 63																					
	0.1 398 75																					
	0.0 358 821																					
	0.0 417 703																					
	1																					
	1																					
	1																					
	1																					
	- 0.1 315 14																					
	- 0.0 620 39																					
	0.0 540 725																					
	0.0 727 683																					
	0.1 963 76																					
	0.1 402 51																					
	0.0 391 522																					
	0.0 448 765																					
<b>Kış</b> – <b>Çıktı</b> <b>Kat-</b> <b>man</b>																						
	<b>Çı</b> <b>ktı</b> <b>Ka</b>																					

	<b>tm an ı Nö ro nu</b>																							
<b>Nö- ron 1</b>	- 0.2 302 78																							
<b>Nö- ron 2</b>	- 0.5 319 1																							
<b>Nö- ron 3</b>	1.0 538 5																							
<b>Nö- ron 4</b>	0.6 627 64																							
<b>BIA S</b>																								
	0.1 256 84																							
<b>Yaz – İlk Kat- man</b>																								
	<b>Nö- ron 1</b>	<b>Nö- ron 2</b>	<b>Nö- ron 3</b>	<b>Nö- ron 4</b>	<b>Nö- ron 5</b>	<b>Nö- ron 6</b>	<b>Nö- ron 7</b>	<b>Nö- ron 8</b>	<b>Nö- ron 9</b>	<b>Nö- ron 10</b>	<b>Nö- ron 11</b>	<b>Nö- ron 12</b>	<b>Nö- ron 13</b>	<b>Nö- ron 14</b>	<b>Nö- ron 15</b>	<b>Nö- ron 16</b>	<b>Nö- ron 17</b>	<b>Nö- ron 18</b>	<b>Nö- ron 19</b>	<b>Nö- ron 20</b>	<b>Nö- ron 21</b>	<b>Nö- ron 22</b>	<b>Nö- ron 23</b>	<b>Nö- ron 24</b>
<b>Girdi Nö- ronu</b>	0.5 671 1	0.37 952 3	- 0.07 824 02	- 0.00 613 875	- 0.43 581 2	- 0.48 174 1	- 0.45 734 7	- 0.14 439 8	- 0.20 698 5	- 0.26 614	- 0.40 275 8	- 0.44 115 6	- 0.15 263 6	- 0.61 371 4	- 0.48 43	- 0.35 550 9	- 0.40 111 4	- 0.06 739 77	- 0.06 239 06	- 0.56 854 4	- 0.42 412 8	- 0.42 924 9	- 0.12 85	- 0.21 668 6
<b>Nö- ron 1</b>	- 0.2 592 97	- 0.18 876 2	- 0.12 833 7	- 0.00 847 712	- 0.15 586 6	- 0.14 938 7	- 0.21 415	- 0.16 118 9	- 0.00 760 119	- 0.41 962 6	- 0.10 431 2	- 0.16 804 4	- 0.49 490 8	- 0.12 875 3	- 0.00 771 936	- 0.04 567 06	- 0.02 231 58	- 0.18 147 7	- 0.35 043 6	- 0.10 336 5	- 0.18 309 6	- 0.15 670 2	- 0.23 942 2	- 0.02 990 19
<b>Nö- ron 2</b>	0.1 953 15	0.20 798 2	- 0.07 842 78	- 0.03 543 64	- 0.13 080 6	- 0.02 351 99	- 0.24 500 9	- 0.09 140 47	- 0.29 436 6	- 0.11 495 1	- 0.07 228 12	- 0.24 553 5	- 0.08 221 33	- 0.41 414 8	- 0.13 593 7	- 0.44 596 9	- 0.32 922 1	- 0.34 504 1	- 0.00 140 125	- 0.13 675 8	- 0.05 738 64	- 0.11 478 4	- 0.03 019 46	- 0.02 438 85
<b>Nö- ron 3</b>	0.2 220 12	- 0.10 06	0.05 314 06	- 0.06 06	0.23 213 5	- 0.05 067 17	0.05 967 17	0.09 451 5	- 0.00 000	0.26 139 9	- 0.30 030	- 0.11 284	- 0.13 013	0.13 900 1	0.27 686 5	0.19 669 2	- 0.20 020	0.30 519 3	0.13 589	0.50 189 7	- 0.02 061 6	0.35 061 3	0.03 192 3	0.08 751 56

		074 2		083 8		826 91			662 273		308 9		416 3				721 7				388 1			
<b>Nö- ron 4</b>	- 0.1 474 42	0.38 764 8	0.22 166 8	- 0.01 878 36	0.29 861 2	- 0.03 150 5	- 0.19 207 7	- 0.29 384 3	0.06 522 35	- 0.01 669 43	0.32 154 4	0.22 756 8	- 0.14 586 9	- 0.30 387 8	0.03 884 73	- 0.13 912	- 0.07 113 34	0.05 697 76	0.25 348 5	0.02 801 28	0.17 198 9	0.37 229	0.04 735 15	- 0.16 474 3
<b>Nö- ron 5</b>	0.0 316 491	0.21 325 5	- 0.07 189 46	0.22 678 1	0.22 089 1	0.40 062 8	- 0.10 261 7	0.27 638 4	- 0.11 682 3	- 0.17 717 4	0.25 654 3	0.35 436 4	0.16 197 8	0.17 105 5	- 0.06 369 27	0.09 466 86	- 0.08 074 04	0.27 467 2	0.04 185 61	0.17 749 5	- 0.05 676 36	- 0.22 267 9	- 0.11 762 2	0.33 749 7
<b>Nö- ron 6</b>	0.1 221 09	0.19 156 5	- 0.12 490 5	- 0.39 469 3	0.04 957 69	0.12 863 1	0.20 651 5	0.15 683 8	0.04 034 21	- 0.12 499 5	- 0.04 324 64	0.14 891 7	- 0.08 553 32	0.07 164 69	0.25 793 2	0.24 425 3	- 0.41 208 6	0.15 271 7	- 0.20 681	- 0.12 258 2	0.43 807 6	- 0.18 162	0.01 861 32	- 0.18 613 4
<b>BIA S</b>																								
	0.2 073 82																							
	0.1 673 47																							
	0.0 535 848																							
	0.2 285 45																							
	0.0 067 004																							
	0.1 360 55																							
	1																							
	1																							
	1																							
	1																							
	1																							
	1																							
	- 0.1 762 89																							
	0.1 197 23																							
	0.0 109 258																							

	- 0.1 639 51																								
	0.0 625 667																								
	- 0.1 501 98																								
	0.2 145 8																								
	0.1 680 77																								
	0.0 509 245																								
	0.2 270 16																								
	0.0 140 836																								
	0.1 438 32																								
Yaz – İkin ci Kat- man																									
	Nö- ron 1	Nö- ron 2	Nö- ron 3	Nö- ron 4	Nö- ron 5	Nö- ron 6	Nö- ron 7	Nö- ron 8	Nö- ron 9	Nö- ron 10	Nö- ron 11	Nö- ron 12	Nö- ron 13	Nö- ron 14	Nö- ron 15	Nö- ron 16									
Nö- ron 1	- 0.8 413 45	0.20 444 7	- 0.73 675 4	- 0.06 587 7	- 0.02 154 09	- 0.45 467	- 0.24 187 7	- 0.47 569 1	- 0.09 003 5	- 0.66 214 1	0.54 592 2	- 0.51 243 4	- 0.01 593 32	- 0.34 399 7	0.27 580 1	- 0.33 702 7									
Nö- ron 2	- 0.1 468 85	0.74 428 8	0.34 910 8	0.32 859 5	0.52 145 8	0.14 705 7	- 0.02 837 2	0.03 735 14	0.12 449 4	0.26 417 3	- 0.62 056 7	0.26 018 2	- 0.07 865 15	0.63 498 4	- 0.29 173	- 0.09 783 81									
Nö- ron 3	- 0.2 836 84	- 0.79 330 5	- 0.04 799 69	- 0.15 629 9	- 0.25 693	- 0.46 557 8	- 0.02 813 44	- 0.49 529 2	0.35 998 6	- 0.32 905 8	- 0.31 943 8	- 0.20 607 2	- 0.61 965 7	- 0.76 565 7	0.22 162 5	- 0.08 325 85									

<b>Nö- ron 4</b>	- 0.1 712 06	- 0.36 513 8	- 0.66 574 1	- 0.68 579 3	- 0.10 324 9	- 0.07 612 78	0.22 837 6	0.46 758 3	- 0.08 963 71	- 0.37 107 5	0.41 743 3	- 0.17 149	- 0.25 580 1	0.23 121 8	- 0.08 051 56	- 0.42 218 3										
<b>Nö- ron 5</b>	- 0.7 557 92	- 0.59 290 9	- 0.30 640 6	0.26 362 1	- 0.51 318 6	- 0.04 813 52	0.16 419 1	- 0.14 615 1	0.33 786 8	- 0.03 277 97	- 0.28 418 3	- 0.20 718 3	0.24 762 4	- 0.78 195	- 0.56 329 1	- 0.07 732 07										
<b>Nö- ron 6</b>	- 0.2 269 79	- 0.49 044 4	- 0.50 408 9	0.04 237 69	- 0.23 244	0.31 308 9	- 0.45 761 1	- 0.22 991 7	0.28 555 1	- 0.47 410 9	0.56 963 3	- 0.58 944 9	0.69 559 3	- 0.29 031 7	0.13 700 3	0.26 988 3										
<b>Nö- ron 1</b>	0.5 444 47	- 0.09 512 9	- 0.14 276 2	0.01 020 42	- 0.44 202 7	- 0.02 309 61	- 0.04 862 78	0.31 601 7	- 0.01 056 73	0.47 995 1	- 0.00 876 914	0.02 056 66	0.34 418 7	0.00 931 587	0.02 638 65	- 0.16 024 5										
<b>Nö- ron 2</b>	- 0.3 394 21	0.06 777 65	0.25 141 3	0.47 629 1	- 0.50 069 3	- 0.04 615 15	0.30 727 3	- 0.05 807 5	0.08 562 4	0.12 046 1	- 0.07 392 53	0.31 096 5	- 0.21 156 4	0.19 820 6	0.14 611	0.10 062 7										
<b>Nö- ron 3</b>	0.2 096 3	0.14 831 2	0.49 170 1	0.07 431 41	0.23 035 6	0.47 737 2	- 0.08 755 06	0.00 890 782	0.08 931 19	0.00 451 315	- 0.39 925 5	0.24 361 3	0.19 661 8	- 0.13 032 2	- 0.30 893 1	0.14 228 2										
<b>Nö- ron 4</b>	- 0.0 433 188	- 0.03 108 02	0.36 996 9	0.15 916 1	0.05 692 85	- 399	0.17 029 9	- 0.21 862 5	- 0.21 585 1	0.10 475 9	- 0.37 307 7	- 0.42 659 5	0.02 976 85	0.30 787 4	- 0.20 242 2	0.28 341 6										
<b>BIA S</b>																										
	0.3 089 36																									
	0.2 914 9																									
	0.1 874 36																									
	0.2 170 38																									
	1																									
	1																									
	1																									
	1																									
	- 0.2 496 99																									

	0.2 400 82																						
	- 0.1 561 99																						
	0.1 410 83																						
	0.3 115 65																						
	0.2 899 11																						
	0.1 873 94																						
	0.2 161 17																						
<b>Yaz - Çi- kış Kat- man</b>																							
	<b>Çi ktı Ka tm an ı Nö ro nu</b>																						
<b>Nö- ron 1</b>	- 0.4 881 43																						
<b>Nö- ron 2</b>	0.3 687 02																						
<b>Nö- ron 3</b>	- 0.7 040 48																						
<b>Nö- ron 4</b>	0.8 540 16																						





- [12] M. E. Ekinici, *Destek Vektör Regresyon ile Hava Kirliliği Tahmini*, 2017.
- [13] Bestami Taşar, et al. «Yapay sinir ağları yöntemi kullanılarak buharlaşma miktarı tahmini,» *DÜMF Mühendislik Dergisi*, pp. 543 - 551, 2018.
- [14] E. Alpaydın, *Yapay Öğrenme: Yeni Yapay Zeka, Tellekt Yayınları*, 2018.
- [15] M. D. Selahattin Yavuz, «İstatiksel Normalizasyon Tekniklerinin Yapay Sinir Ağı Performansına Etkisi,» *Erciyes Üniversitesi İktisadi ve İdari Bilimler Fakültesi Dergisi*, pp. 167-187, 2012.
- [16] A. Kara, «Uzun-Kısa Süreli Bellek Ağı Kullanarak Global Güneş Işınımı Zaman Serileri Tahmini,» *Fen Bilimleri Dergisi*, pp. 882-892, 2019.
- [17] B. K. İbrahim Ali Metin, «İnsan Aktivitelerinin Sınıflandırılmasında Tekrarlayan Sinir Ağı Kullanan Derin Öğrenme Tabanlı Yaklaşım,» *Veri Bilimi Dergisi*, pp. 1-10, 2019.
- [18] A. A. Süzen, «Lstm Derin Sinir Ağları İle Üniversite Giriş Sınavındaki Matematik Soru Sayılarının Konulara Göre Tahmini,» *Engineering Sciences (NWSAENS)*, pp. 112-118, 2019.
- [19] Y. Y. Yueleı Xiao, «Hybrid LSTM Neural Network for Short-Term TrafficFlow Prediction,» *Multidisciplinary Digital Publishing Institute*, 2019.
- [20] K. Kabil, *Makine Öğrenmesinde Ayırık Öbekleme Ve Sınıflandırma Algoritmaları*, 2019.
- [21] J. L. Devore, *Probability and Statistics for Engineeringand the Sciences*, 2012.